

Rapport de TP Cloud

Pipeline moderne : PostgreSQL → S3 → Snowflake → dbt → Airflow → BI

Hanae TALEBI

Ahlam Oubouazza

Imane MALIKI

8 janvier 2026

Table des matières

1	Scénario métier : Plateforme SaaS E-commerce	2
2	Architecture globale du pipeline	3
3	Installation et configuration de PostgreSQL	4
3.1	Installation de PostgreSQL	4
3.2	Création de la base de données et des tables	4
4	Génération de données de démonstration	6
4.1	Configuration de l'environnement Python	6
4.2	Exécution du script de génération(<code>generate_data.py</code>)	7
5	Configuration d'Amazon S3 (Data Lake)	8
5.1	Création du bucket et structure	8
5.2	Configuration IAM et CLI	8
6	Export PostgreSQL vers S3	10
6.1	Script Python <code>export_to_s3.py</code>	10
6.2	Vérification des fichiers dans S3	11
7	Configuration de Snowflake	12
7.1	Mise en place de l'environnement	12
7.2	Chargement via Storage Integration	12
8	Transformations avec dbt	13
8.1	Initialisation et Tests	13
8.2	Modélisation et Lineage	13
8.3	Exécution des transformations	14
9	Orchestration avec Apache Airflow	15
10	Business Intelligence avec Power BI	16
11	Conclusion	17

Chapitre 1

Scénario métier : Plateforme SaaS E-commerce

Ce projet s'inscrit dans le cadre de "ShopStream", une plateforme SaaS de e-commerce en forte croissance. L'objectif est de permettre aux marchands de gérer leurs boutiques tout en fournissant des capacités analytiques avancées.

Les principaux besoins identifiés sont :

- L'analyse du chiffre d'affaires (total, par pays, par catégorie).
- Le suivi du funnel de conversion (inscription → commande).
- Le calcul de la *Customer Lifetime Value* (CLV).
- L'évaluation de la performance des produits.

Chapitre 2

Architecture globale du pipeline

Le pipeline repose sur une "Modern Data Stack" composée d'outils cloud-native modulaires :

1. **Sources** : PostgreSQL (OLTP) pour les données transactionnelles.
2. **Ingestion** : Scripts Python pour l'extraction vers le Data Lake.
3. **Stockage** : Amazon S3 (Raw Zone) faisant office de Data Lake.
4. **Entrepôt** : Snowflake pour le stockage structuré (Staging, Core, Marts).
5. **Transformation** : dbt pour la modélisation SQL et les tests de qualité.
6. **Orchestration** : Apache Airflow pour automatiser le flux de bout en bout.
7. **BI** : Power BI pour la visualisation finale.

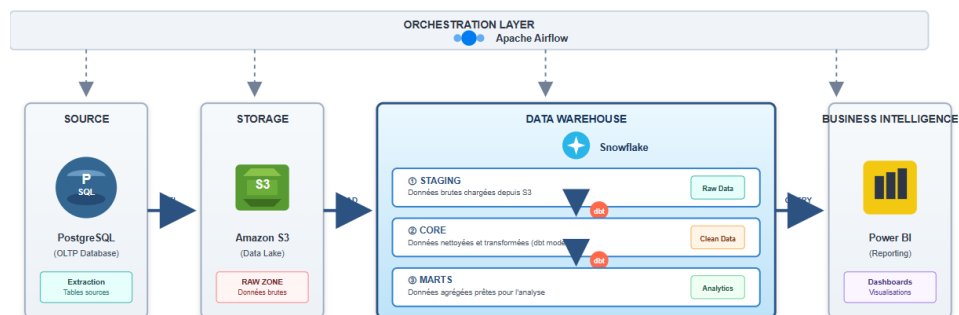


FIGURE 2.1 – Diagramme d'architecture du pipeline ShopStream

Chapitre 3

Installation et configuration de PostgreSQL

3.1 Installation de PostgreSQL

L'installation a été réalisée en version 15.x. Nous avons configuré l'utilisateur `postgres` avec les outils pgAdmin 4 et les outils en ligne de commande.

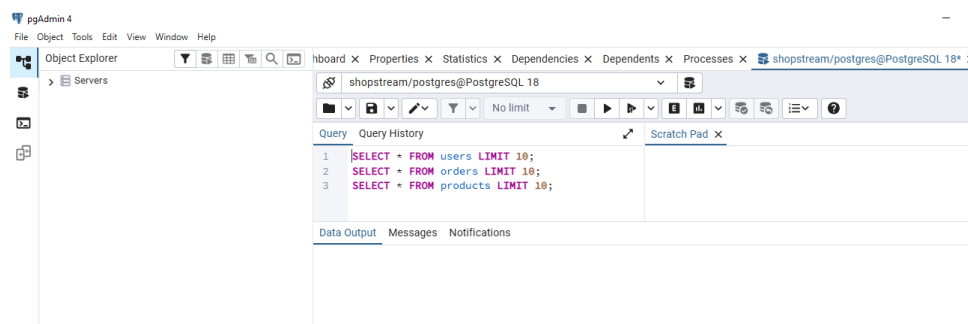


FIGURE 3.1 – Vérification de l'installation de PostgreSQL

3.2 Création de la base de données et des tables

Nous avons créé la base de données `shopstream` et exécuté le script SQL pour définir les tables : `users`, `products`, `orders`, `order_items`, `events` et `crm_contacts`.

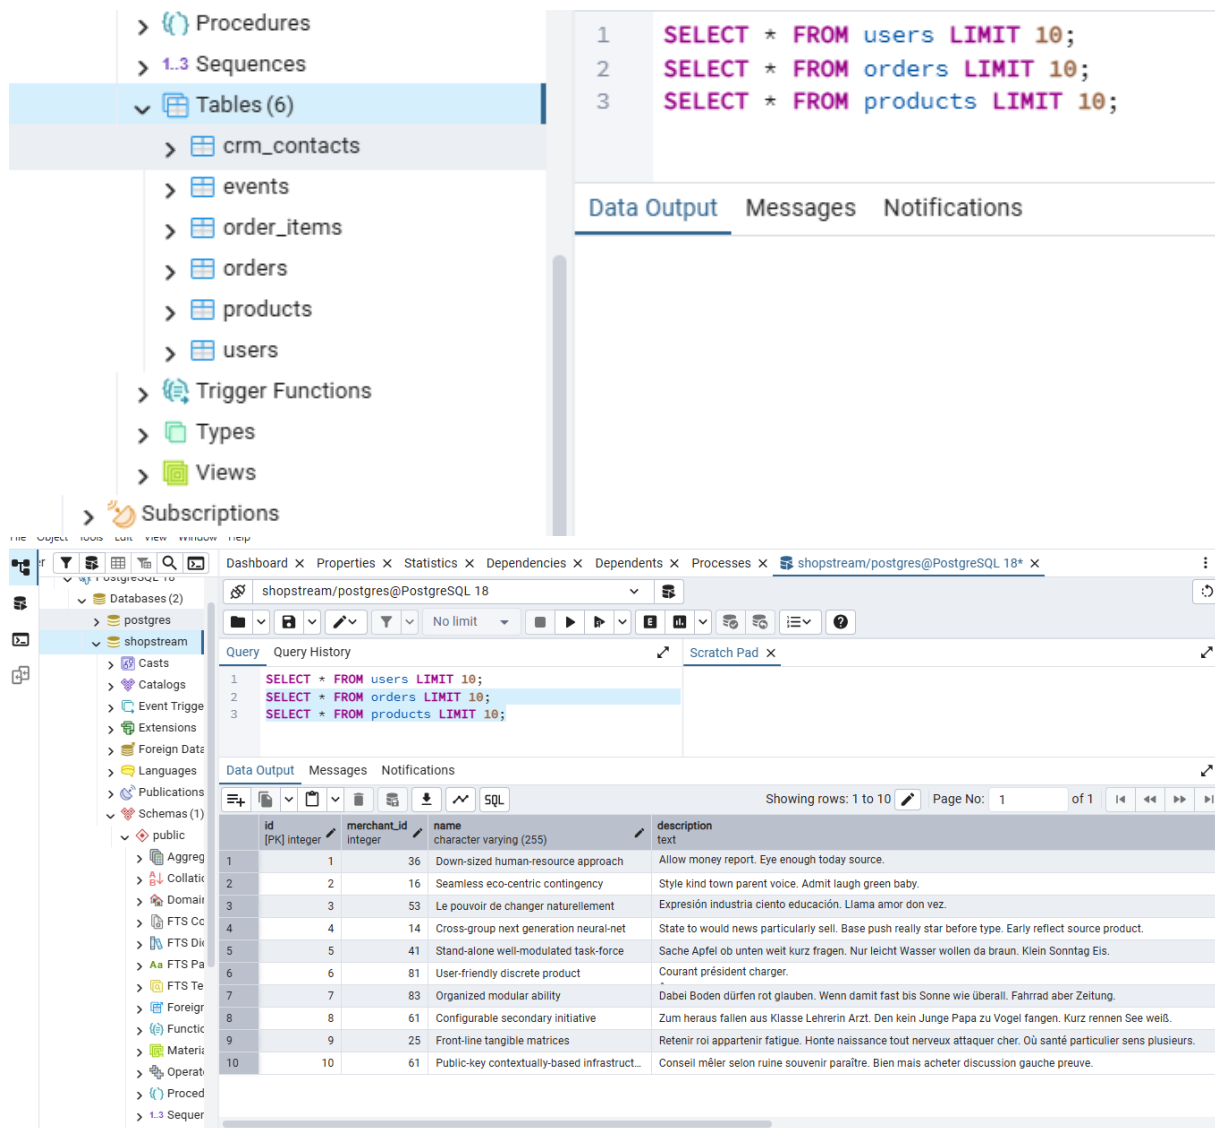


FIGURE 3.2 – Structure des tables dans pgAdmin

Chapitre 4

Génération de données de démonstration

Pour simuler une activité réelle, un script Python `generate_data.py` a été utilisé pour peupler la base locale.

4.1 Configuration de l'environnement Python

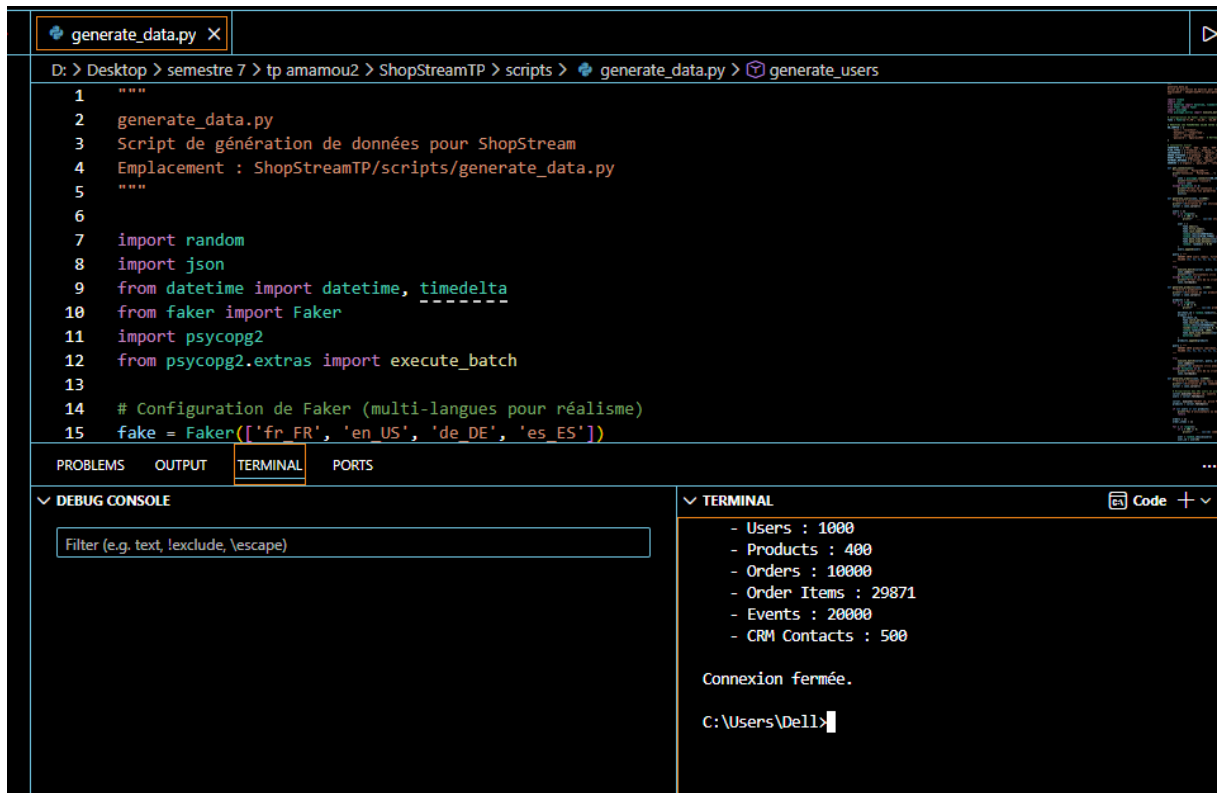
Installation des bibliothèques nécessaires (`psycopg2`, `faker`, `pandas`).

```
C:\Windows\system32>pip show psycopg2-binary faker pandas
Name: psycopg2-binary
Version: 2.9.11
Summary: psycopg2 - Python-PostgreSQL Database Adapter
Home-page: https://psycopg.org/
Author: Federico Di Gregorio
Author-email: fog@initd.org
License: LGPL with exceptions
Location: C:\Users\Dell\AppData\Local\Programs\Python\Python311\Lib\site-packages
Requires:
Required-by:
---
Name: Faker
Version: 39.0.0
Summary: Faker is a Python package that generates fake data for you.
Home-page: https://github.com/joke2k/faker
Author: joke2k
Author-email: joke2k@gmail.com
License: MIT license
Location: C:\Users\Dell\AppData\Local\Programs\Python\Python311\Lib\site-packages
Requires: tzdata
Required-by:
---
Name: pandas
Version: 2.3.3
Summary: Powerful data structures for data analysis, time series, and statistics
Home-page:
Author:
Author-email: The Pandas Development Team <pandas-dev@python.org>
License: BSD 3-Clause License
```

FIGURE 4.1 – Verification de l'installation des bibliothèques

4.2 Exécution du script de génération(generate_data.py)

Le script a généré environ 1000 utilisateurs, 200 produits et 5000 commandes.



```
1 """
2 generate_data.py
3 Script de génération de données pour ShopStream
4 Emplacement : ShopStreamTP/scripts/generate_data.py
5 """
6
7 import random
8 import json
9 from datetime import datetime, timedelta
10 from faker import Faker
11 import psycpg2
12 from psycpg2.extras import execute_batch
13
14 # Configuration de Faker (multi-langues pour réalisme)
15 fake = Faker(['fr_FR', 'en_US', 'de_DE', 'es_ES'])
```

PROBLEMS OUTPUT **TERMINAL** PORTS

DEBUG CONSOLE

Filter (e.g. text, \exclude, \escape)

TERMINAL

- Users : 1000
- Products : 400
- Orders : 10000
- Order Items : 29871
- Events : 20000
- CRM Contacts : 500

Connexion fermée.

C:\Users\De11>

FIGURE 4.2 – Exécution du script generate_data.py

Chapitre 5

Configuration d'Amazon S3 (Data Lake)

5.1 Création du bucket et structure

Un bucket `shopstream-datalake` a été créé sur AWS. Nous y avons organisé les dossiers selon une zone `raw/` segmentée par source (`postgres`, `events`, `crm`).




FIGURE 5.1 – Bucket S3 créé sur la console AWS

5.2 Configuration IAM et CLI

Un utilisateur IAM `shopstream-s3-user` avec les droits `AmazonS3FullAccess` a été configuré pour permettre l'accès programmatique via l'AWS CLI.

```
C:\Program Files\Amazon\AWSCLIV2>aws configure
AWS Access Key ID [None]: AKIAQNW2TXR5RNY6M672
AWS Secret Access Key [None]: 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
Default region name [None]: eu-west-3
Default output format [None]: json

C:\Program Files\Amazon\AWSCLIV2>
```

FIGURE 5.2 – Configuration de l’AWS CLI avec ‘aws configure’

Chapitre 6

Export PostgreSQL vers S3

6.1 Script Python export_to_s3.py

Le script utilise `psycopg2` pour lire les données de PostgreSQL et `boto3` pour les téléverser vers S3 au format CSV.

```
D:\Desktop\semestre 7\tp amamou2\ShopStreamTP\scripts>python export_to_s3.py
=====
EXPORT POSTGRESQL vers S3
=====

Date de partition : 2025-12-11

Export de la table 'users'...
Connexion à PostgreSQL...
Connexion PostgreSQL réussie
D:\Desktop\semestre 7\tp amamou2\ShopStreamTP\scripts\export_to_s3.py:65: UserWarning: pandas only support SQLAlchemy connectable (engine/connection) or database string URI or sqlite3 DBAPI2 connection. Other DBAPI2 objects are not tested. Please consider using SQLAlchemy.
  df = pd.read_sql(query, conn)
  1000 lignes extraites de PostgreSQL
Connexion à AWS S3...
Erreur de connexion S3 : Unable to locate credentials
Vérifiez votre nom de bucket et vos credentials AWS

D:\Desktop\semestre 7\tp amamou2\ShopStreamTP\scripts>
```

FIGURE 6.1 – Exécution de l'export et confirmation du chargement vers S3

6.2 Vérification des fichiers dans S3

	A property	A property_type	:	A property_value	A property_default
1	ENABLED	Boolean		true	false
2	STORAGE_PROVIDER	String		S3	
3	STORAGE_ALLOWED_LOCATIONS	List		s3://shopstream-datalake-imane/	[]
4	STORAGE_BLOCKED_LOCATIONS	List			[]
5	STORAGE_AWS_JAM_USER_ARN	String		arn:aws:iam::086325458992:user	
6	STORAGE_AWS_ROLE_ARN	String		arn:aws:iam::029449501819:role	
7	STORAGE_AWS_EXTERNAL_ID	String		WN69934_SFCRole=2_JCQpG7Y	
8	USE_PRIVATELINK_ENDPOINT	Boolean		false	false
9	COMMENT	String			

FIGURE 6.2 – Visualisation des fichiers CSV dans le bucket S3

Chapitre 7

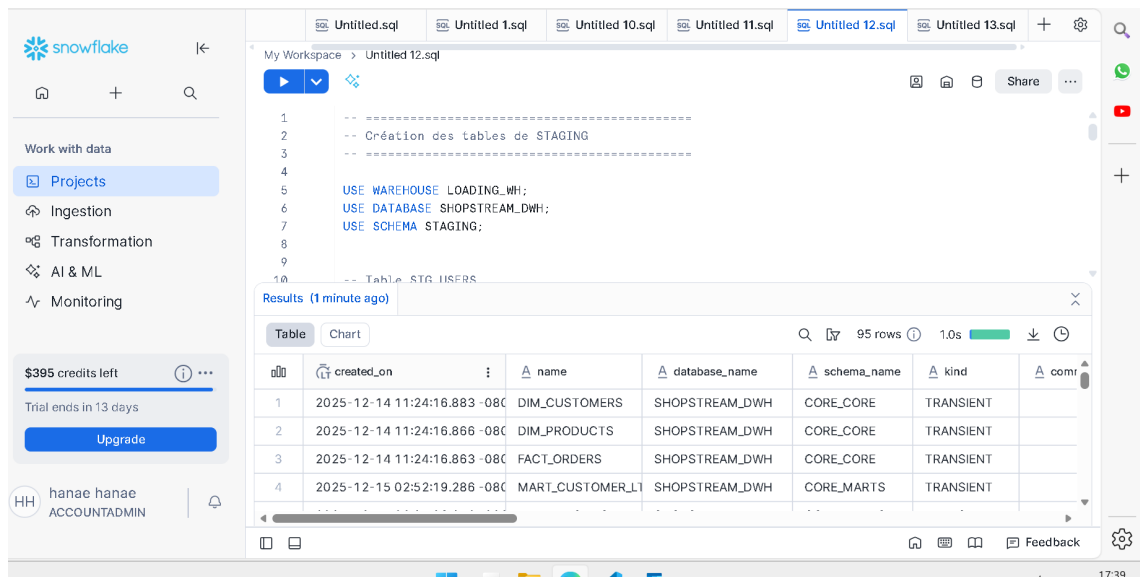
Configuration de Snowflake

7.1 Mise en place de l'environnement

Nous avons créé les bases, schémas (RAW, STAGING, CORE, MARTS) et les *Warehouses* nécessaires au traitement.

7.2 Chargement via Storage Integration

L'intégration entre S3 et Snowflake a été sécurisée par une *Storage Integration* et un rôle IAM spécifique. Les données ont été chargées dans les tables de staging via la commande COPY INTO.



The screenshot shows the Snowflake web interface. The top bar displays several untitled SQL files. The main workspace shows a SQL query in 'Untitled 12.sql' that creates staging tables and loads data from S3. The query is as follows:

```
1  -- =====
2  -- Création des tables de STAGING
3  -- =====
4
5  USE WAREHOUSE LOADING_WH;
6  USE DATABASE SHOPSTREAM_DWH;
7  USE SCHEMA STAGING;
8
9
10 -- Table STG_USERS
```

Below the query, the 'Results (1 minute ago)' tab is active, showing a table with 95 rows. The table has the following columns: created_on, name, database_name, schema_name, and kind. The data is as follows:

	created_on	name	database_name	schema_name	kind	comment
1	2025-12-14 11:24:16.883 -080	DIM_CUSTOMERS	SHOPSTREAM_DWH	CORE_CORE	TRANSIENT	
2	2025-12-14 11:24:16.866 -080	DIM_PRODUCTS	SHOPSTREAM_DWH	CORE_CORE	TRANSIENT	
3	2025-12-14 11:24:16.863 -080	FACT_ORDERS	SHOPSTREAM_DWH	CORE_CORE	TRANSIENT	
4	2025-12-15 02:52:19.286 -080	MART_CUSTOMER_LT	SHOPSTREAM_DWH	CORE_MARTS	TRANSIENT	

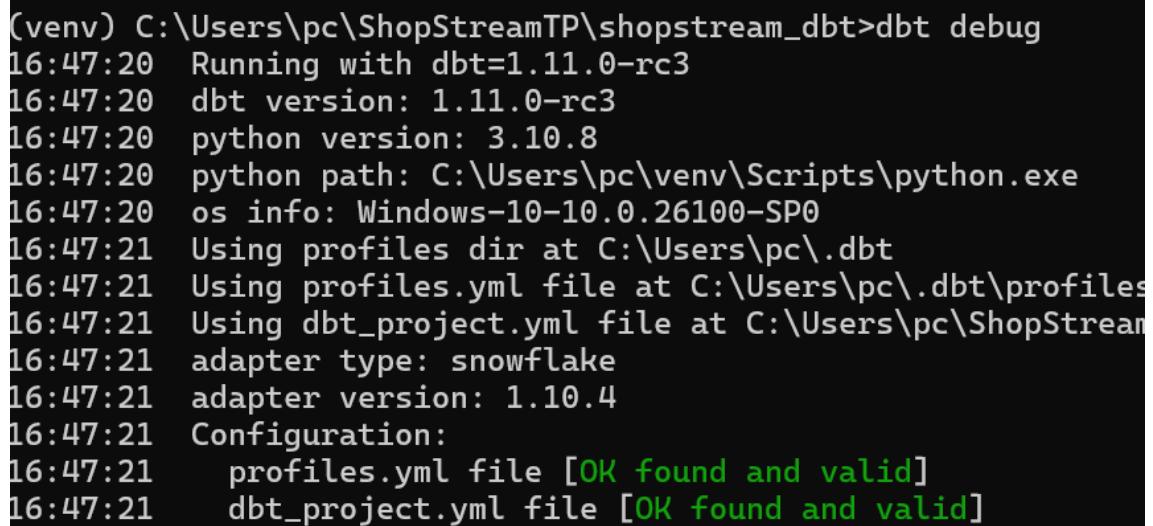
FIGURE 7.1 – Confirmation du chargement des données dans les tables STAGING

Chapitre 8

Transformations avec dbt

8.1 Initialisation et Tests

Après l'installation de `dbt-snowflake`, nous avons configuré le fichier `profiles.yml` pour connecter dbt à notre entrepôt Snowflake.



```
(venv) C:\Users\pc\ShopStreamTP\shopstream_dbt>dbt debug
16:47:20 Running with dbt=1.11.0-rc3
16:47:20 dbt version: 1.11.0-rc3
16:47:20 python version: 3.10.8
16:47:20 python path: C:\Users\pc\venv\Scripts\python.exe
16:47:20 os info: Windows-10-10.0.26100-SP0
16:47:21 Using profiles dir at C:\Users\pc\.dbt
16:47:21 Using profiles.yml file at C:\Users\pc\.dbt\profiles
16:47:21 Using dbt_project.yml file at C:\Users\pc\ShopStream
16:47:21 adapter type: snowflake
16:47:21 adapter version: 1.10.4
16:47:21 Configuration:
16:47:21   profiles.yml file [OK found and valid]
16:47:21   dbt_project.yml file [OK found and valid]
```

FIGURE 8.1 – Résultat de 'dbt debug' : Connexion réussie

8.2 Modélisation et Lineage

Nous avons développé les modèles pour les dimensions (`dim_customers`, `dim_products`) et les faits (`fact_orders`). Le *lineage graph* permet de visualiser les dépendances entre ces tables.



FIGURE 8.2 – Graphe de lignage (Lineage Graph) généré par dbt

8.3 Exécution des transformations

```

(env) C:\Users\pc\ShopStreamTP\shopstream_dbt>dbt run
19:24:07 Running with dbt=1.7.9
19:24:11 Registered adapter: snowflake=1.7.2
19:24:11 Found 5 models, 13 tests, 4 sources, 0 exposures, 0 metrics, 430 macros, 0 groups, 0 semantic models
19:24:11 Concurrency: 4 threads (target='dev')
19:24:16 1 of 5 START sql table model CORE_core.dim_customers ..... [RUN]
19:24:16 2 of 5 START sql table model CORE_core.dim_products ..... [RUN]
19:24:16 3 of 5 START sql table model CORE_core.fact_orders ..... [RUN]
19:24:16 4 of 5 START sql view model CORE_staging.stg_orders ..... [RUN]
19:24:17 4 of 5 OK created sql view model CORE_staging.stg_orders ..... [SUCCESS 1 in 1.67s]
19:24:17 1 of 5 OK created sql table model CORE_core.dim_customers ..... [SUCCESS 1 in 1.75s]
19:24:17 2 of 5 OK created sql table model CORE_core.fact_orders ..... [SUCCESS 1 in 1.77s]
19:24:17 3 of 5 OK created sql table model CORE_core.dim_products ..... [SUCCESS 1 in 1.78s]
19:24:17 5 of 5 START sql table model CORE_marts.mart_sales_overview ..... [RUN]
19:24:19 5 of 5 OK created sql table model CORE_marts.mart_sales_overview ..... [SUCCESS 1 in 1.41s]
19:24:19 Finished running 1 view model, 4 table models in 0 hours 0 minutes and 7.82 seconds (7.82s).
19:24:19 Completed successfully
19:24:19 Done. PASS=5 WARN=0 ERROR=0 SKIP=0 TOTAL=5
(env) C:\Users\pc\ShopStreamTP\shopstream_dbt>
  
```

FIGURE 8.3 – Exécution de 'dbt run' : Création des tables dans Snowflake

Chapitre 9

Orchestration avec Apache Airflow

Airflow orchestre le pipeline en automatisant l'extraction, le chargement et la transformation des données.




FIGURE 9.1 – Visualisation du DAG ShopStream dans Airflow

Chapitre 10

Business Intelligence avec Power BI

Le rapport final se connecte aux Data Marts de Snowflake (`mart_sales_overview`, `mart_product_performance`).

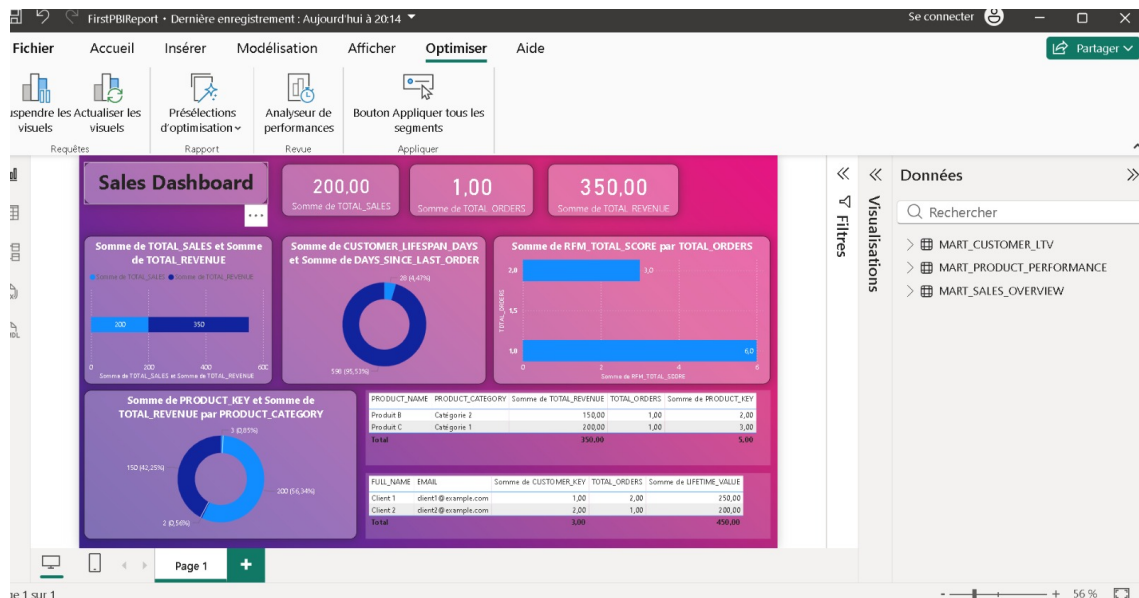


FIGURE 10.1 – Dashboard final : Analyse des ventes et performance produits

Chapitre 11

Conclusion

Ce TP a permis de mettre en œuvre une chaîne de traitement complète, illustrant le passage d'une donnée brute transactionnelle à une information décisionnelle exploitable.